

# Recurrent Neural Networks


Michał Filipiuk




Uwaga: Nie będzie dużo matmy!

# Po co te RNNy?


one to one




one to many




many to one



many to many




many to many




# Trochę historii

- Pierwsze sieci RNNy pojawiają się już w 1986
- Niestety początkowo są tylko naukową ciekawostką z powodu swojej kapryśności
- Naukowcy tworzą dziesiątki różnych implementacji, ale tylko dwie z nich dożywają “dorosłości”:
  - Long short-term memory (1997)
  - Gated recurrent unit (2014)




# Vanilla RNN



# Jak to się uczy?

- “Rozwinięty” RNN jest skierowanym, grafem acyklicznym
- W związku z tym możemy dokonać backpropagacji jak w każdej sieci neuronowej! Super?





# Jak to się uczy?

- “Rozwinięty” RNN jest skierowanym, acyklicznym grafem (w skrócie DAG)
- W związku z tym możemy dokonać backpropagacji jak w każdej sieci neuronowej! Super?


- Rozwijanie RNNów dla długich sekwencji powoduje duże problemy z gradientami:

- “Eksplodujące” gradienty (exploding gradients)


- “Znikające” gradienty (vanishing gradients)

- Rozwiązanie?

Rozwijać tylko do pewnego ustalonego momentu  
(truncated backpropagation through time)

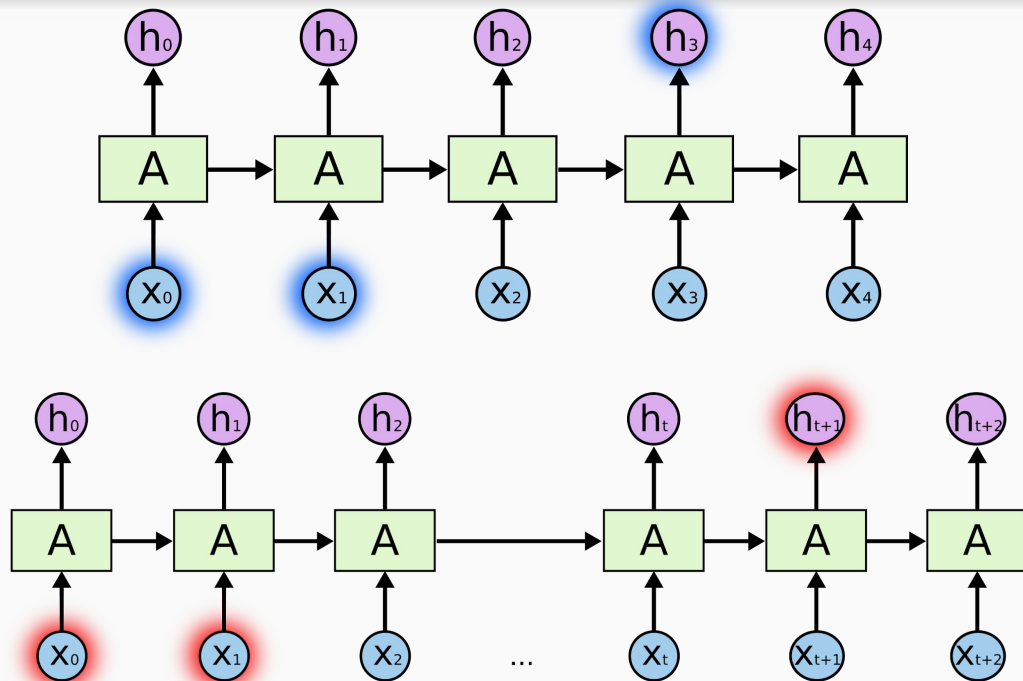


↓ unfold through time ↓


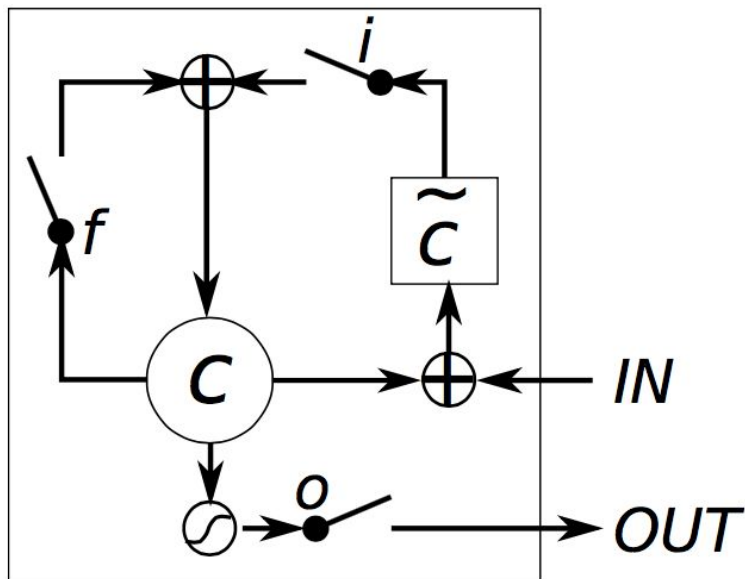





# Jak to się uczy?




# Long short-term memory

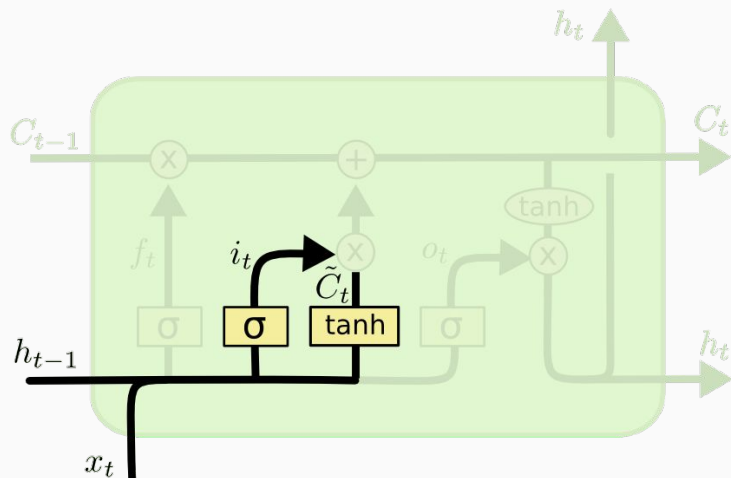


$$\begin{aligned}
 f_t &= \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \\
 i_t &= \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \\
 \tilde{C}_t &= \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \\
 C_t &= f_t * C_{t-1} + i_t * \tilde{C}_t \\
 o_t &= \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \\
 h_t &= o_t * \tanh(C_t)
 \end{aligned}$$






$$f_t = \sigma (W_f \cdot [h_{t-1}, x_t] + b_f)$$



$$i_t = \sigma (W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$



$$o_t = \sigma(W_o [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t * \tanh(C_t)$$

# Long Short Term Memory (LSTM)


[Hochreiter et al., 1997]

**f**: Forget gate, Whether to erase cell

**i**: Input gate, whether to write to cell

**g**: Gate gate (?), How much to write to cell

**o**: Output gate, How much to reveal cell




$$\begin{pmatrix} i \\ f \\ o \\ g \end{pmatrix} = \begin{pmatrix} \sigma \\ \sigma \\ \sigma \\ \tanh \end{pmatrix} W \begin{pmatrix} h_{t-1} \\ x_t \end{pmatrix}$$

$$c_t = f \odot c_{t-1} + i \odot g$$

$$h_t = o \odot \tanh(c_t)$$

# Gated recurrent unit



$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t])$$

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t])$$

$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t])$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

# GRU vs LSTM

## Argumenty za LSTM:

- Większa moc wyrazu (choć nieznacznie)

## Argumenty za GRU:

- Łżejsze w uczeniu
- Łatwiej uogólnia się

Dziękuję za uwagę



# Bibliografia

- <http://www.wildml.com/2015/09/recurrent-neural-networks-tutorial-part-1-introduction-to-rnns/>
- <http://colah.github.io/posts/2015-08-Understanding-LSTMs/>
- <http://karpathy.github.io/2015/05/21/rnn-effectiveness/>
- [https://en.wikipedia.org/wiki/Backpropagation\\_through\\_time](https://en.wikipedia.org/wiki/Backpropagation_through_time)
- [https://en.wikipedia.org/wiki/Recurrent\\_neural\\_network](https://en.wikipedia.org/wiki/Recurrent_neural_network)
- [https://en.wikipedia.org/wiki/Long\\_short-term\\_memory](https://en.wikipedia.org/wiki/Long_short-term_memory)
- [https://brohrer.github.io/how\\_rnn\\_lstm\\_work.html](https://brohrer.github.io/how_rnn_lstm_work.html)
- <https://www.youtube.com/watch?v=6niqTuYFZLQ>